



Fraud Detection

Jupyter Tribe

Oktober 2025



MEET THE TEAM



Iqbal Maulana Fauzi

[Iqbal Maulana Fauzi](#)



Adelia

[Adelia.](#)



Muhsan Maulana

[Muhsan Maulana](#)



Hari Armadianto

[Hari Armadianto](#)



Lukman Permadi

[Lukman Permadi](#)



Aldo Edison

[Aldo Edison](#)



Ismiana Putri

[Ismiana Putri](#)



Jason Cornelius

[Jason Cornelius](#)



Arya Anandita

[Arya Anandita](#)

LATAR BELAKANG DAN TUJUAN

LATAR BELAKANG

Fraud pada sektor perbankan merupakan salah satu tindak kriminal dengan kerugian yang besar. Umumnya, fraud ditemukan pada penggunaan kartu kredit. Fraud pada medium ini terkenal dengan kerugian yang sangat besar. Oleh karena itu, pihak bank harus memberikan perhatian serius terhadap kemungkinan ini.

Kerugian finansial meningkat akibat fraud kartu kredit yang makin kompleks, sementara sistem deteksi konvensional tidak efektif dan sering salah prediksi.

Salah satu solusi yang dapat dikembangkan untuk mengatasi hal ini adalah Fraud Detection System. Dengan sistem ini, transaksi fraud dapat dikenali dan kerugian dapat dihindari / diminimalisir.

TUJUAN

- Menganalisis pola transaksi fraud
- Mengidentifikasi data yang bisa menjadi indikator transaksi fraud
- Mengembangkan model yang dapat mengenali transaksi fraud



DATASET OVERVIEW

Sumber Data: fraudTest.csv

Informasi Statistik Standar:										# 2. Jumlah baris dan kolom	# 4. Ada tidaknya missing value	
	count	mean	min	25%	50%	75%	max	std		print(f"\nJumlah Baris: {df.shape[0]}")	print(f"Jumlah Kolom: {df.shape[1]}")	print(f"\nMissing Values per Kolom:\n{df.isnull().sum()}")
Unnamed: 0	555719.0	277859.0	0.0	138929.5	277859.0	416788.5	555718.0	160422.401459		Jumlah Baris: 555719	Jumlah Kolom: 23	Missing Values per Kolom:
trans_date_trans_time	555719	2020-10-02 01:54:25.166780672	2020-06-21 12:14:25	2020-08-09 06:10:27.500000	2020-10-03 00:59:48	2020-12-01 03:03:04	2020-12-31 23:59:34	NaN				Unnamed: 0 0 trans_date_trans_time 0 cc_num 0 merchant 0 category 0 amt 0 first 0 last 0 gender 0 street 0 city 0 state 0 zip 0 lat 0 long 0 city_pop 0 job 0 dob 0 trans_num 0 unix_time 0 merch_lat 0 merch_long 0 is_fraud 0 dtype: int64
cc_num	555719.0	41783695528764096.0	60416207185.0	180042946491150.0	3521417320836166.0	4635330563105903.0	4992346398065154048.0	1309836622980698624.0				
amt	555719.0	69.39281	1.0	9.63	47.29	83.01	22768.11	156.745941				
zip	555719.0	48842.628015	1257.0	26292.0	48174.0	72011.0	99921.0	26855.283328				
lat	555719.0	38.543253	20.0271	34.6689	39.3716	41.8948	65.6899	5.061336				
long	555719.0	-90.231325	-165.6723	-96.798	-87.4769	-80.1752	-67.9503	13.72178				
city_pop	555719.0	88221.887918	23.0	741.0	2408.0	19685.0	2906700.0	300390.892061				
unix_time	555719.0	1380678865.16678	1371816865.0	1376028627.5	1380761988.0	1385866984.0	1388534374.0	5201104.065916				
merch_lat	555719.0	38.542798	19.027422	34.755302	39.376593	41.954163	66.679297	5.095829				
merch_long	555719.0	-90.23138	-166.671575	-96.905129	-87.445204	-80.264637	-66.952026	13.733071				
is_fraud	555719.0	0.00386	0.0	0.0	0.0	0.0	1.0	0.062008				

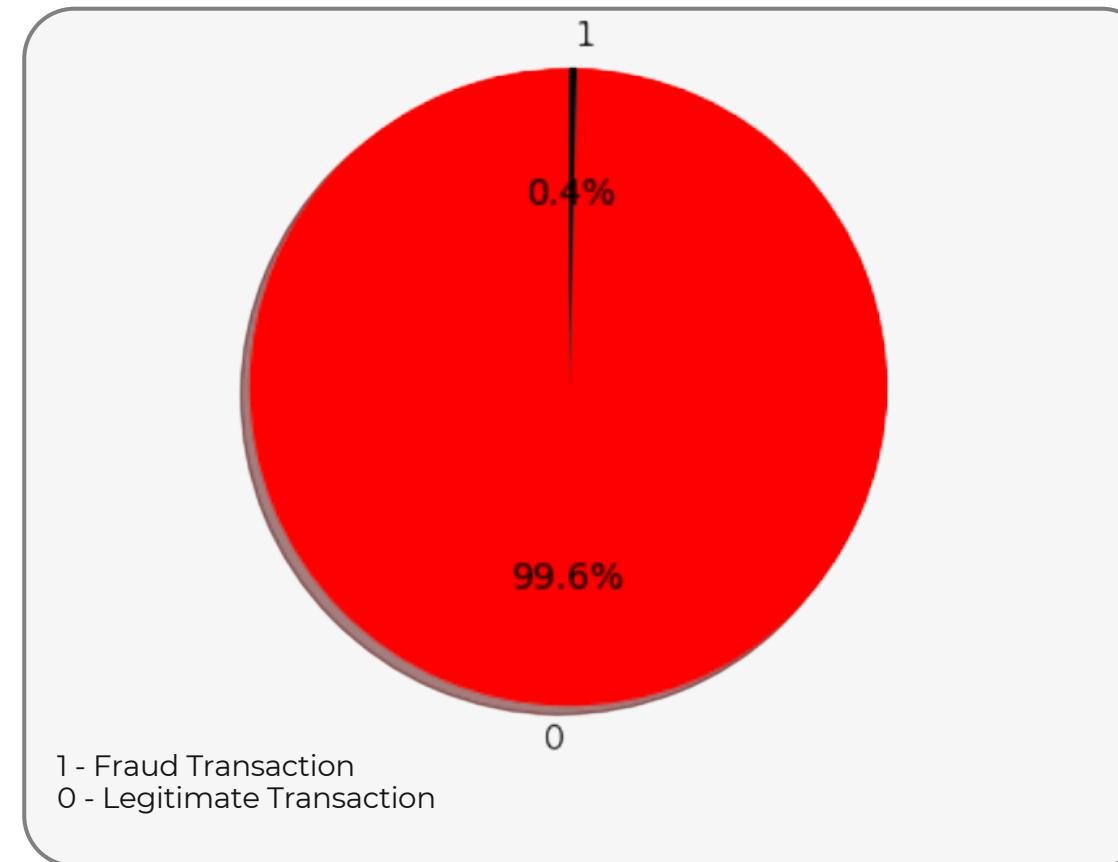
informasi statistik standar

informasi jumlah baris, kolom, data awal & data akhir

informasi missing values & data duplikat

dimensi data	<ul style="list-style-type: none"> kolom: 23 kolom baris: 555.719 baris 	data awal dan data akhir	<ul style="list-style-type: none"> awal: 2020-06-21 12:14:25 akhir: 2020-12-31 23:59:34
mising value	<ul style="list-style-type: none"> tidak ditemukan missing value 	data duplikat	<ul style="list-style-type: none"> tidak ditemukan data duplikat
nama kolom	<ul style="list-style-type: none"> trans_date_trans_time cc_num merchant category amt first last 	<ul style="list-style-type: none"> gender street city state zip lat long city_pop 	<ul style="list-style-type: none"> job dob trans_num unix_time merch_lat merch_long is_fraud

DATASET OVERVIEW



About

Dataset memuat riwayat transaksi kartu kredit dari tanggal 21 Juni 2020 hingga 31 Desember 2020

Transaksi Fraud

Pada dataset, terdapat kolom "is_fraud" yang merupakan indikator transaksi fraud atau legitimate

Jumlah Transaksi

Total transaksi pada dataset adalah **555.719** dari 924 kartu kredit

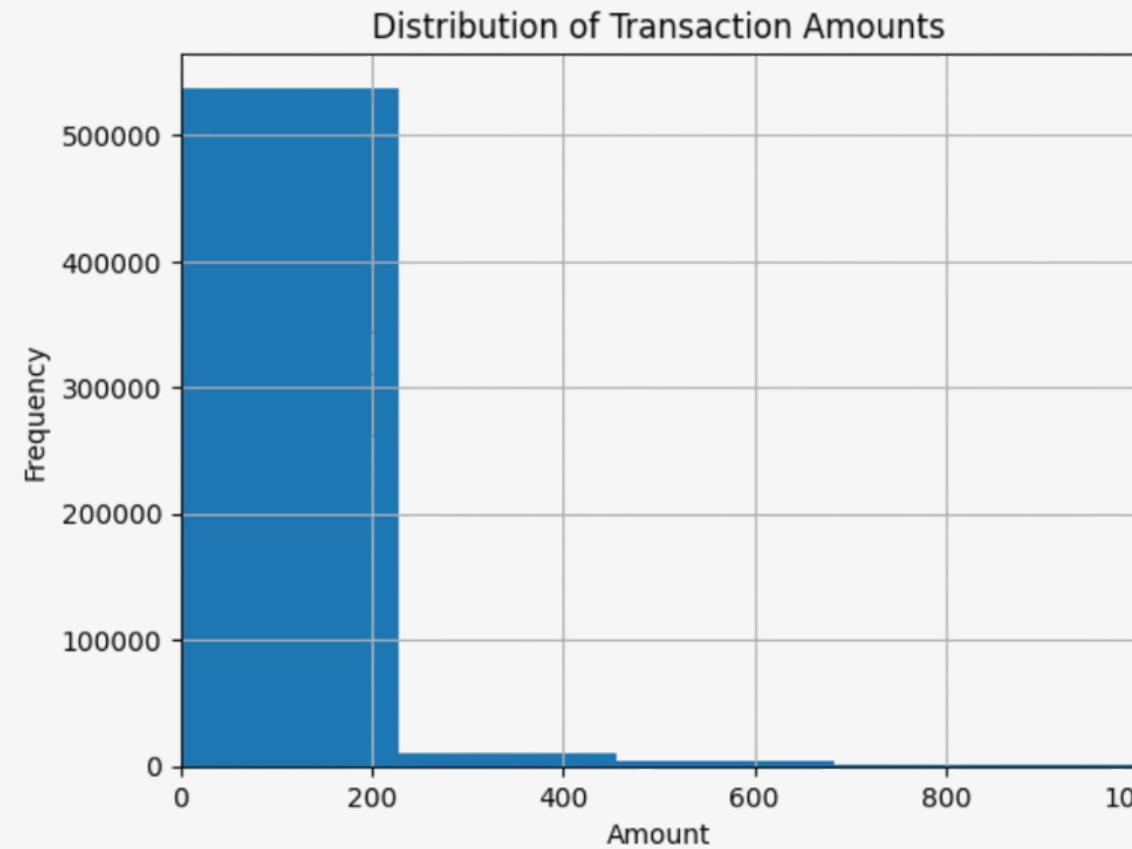
Imbalanced Data

Pada dataset, terdapat kolom "is_fraud" yang merupakan indikator transaksi fraud atau legitimate

Unnamed: 0	trans_date_trans_time	cc_num	merchant	category	amt	first	last	gender	street	...	lat	long	city_pop	job	dob	trans_num	unix_time	merch_lat	merch_long	is_fraud
0	0	2020-06-21 12:14:25	2291163933867244	fraud_Kirlin and Sons	personal_care	2.86	Jeff	Elliott	M	351 Darlene Green	33.9659	-80.9355	333497	Mechanical engineer	1968-03-19	2da90c7d74bd46a0caf3777415b3ebd3	1371816865	33.986391	-81.200714	0
1	1	2020-06-21 12:14:33	3573030041201292	fraud_Sporer-Keebler	personal_care	29.84	Joanne	Williams	F	3638 Marsh Union	40.3207	-110.4360	302	Sales professional, IT	1990-01-17	324cc204407e99f51b0d6ca0055005e7	1371816873	39.450498	-109.960431	0
2	2	2020-06-21 12:14:53	3598215285024754	fraud_Swaniawski, Nitzsche and Welch	health_fitness	41.28	Ashley	Lopez	F	9333 Valentine Point	40.6729	-73.5365	34496	Librarian, public	1970-10-21	c81755dbbbea9d5c77f094348a7579be	1371816893	40.495810	-74.196111	0
3	3	2020-06-21 12:15:15	3591919803438423	fraud_Haley Group	misc_pos	60.05	Brian	Williams	M	32941 Krystal Mill Apt. 552	28.5697	-80.8191	54767	Set designer	1987-07-25	2159175b9efe66dc301f149d3d5abf8c	1371816915	28.812398	-80.883061	0
4	4	2020-06-21 12:15:17	3526826139003047	fraud_Johnston-Casper	travel	3.19	Nathan	Massey	M	5783 Evan Roads Apt. 465	44.2529	-85.0170	1126	Furniture designer	1955-07-06	57ff021bd3f328f8738bb535c302a31b	1371816917	44.959148	-85.884734	0

EKSPLORASI DATA DAN FEATURE ENGINEERING

NOMINAL TRANSAKSI (AMT)

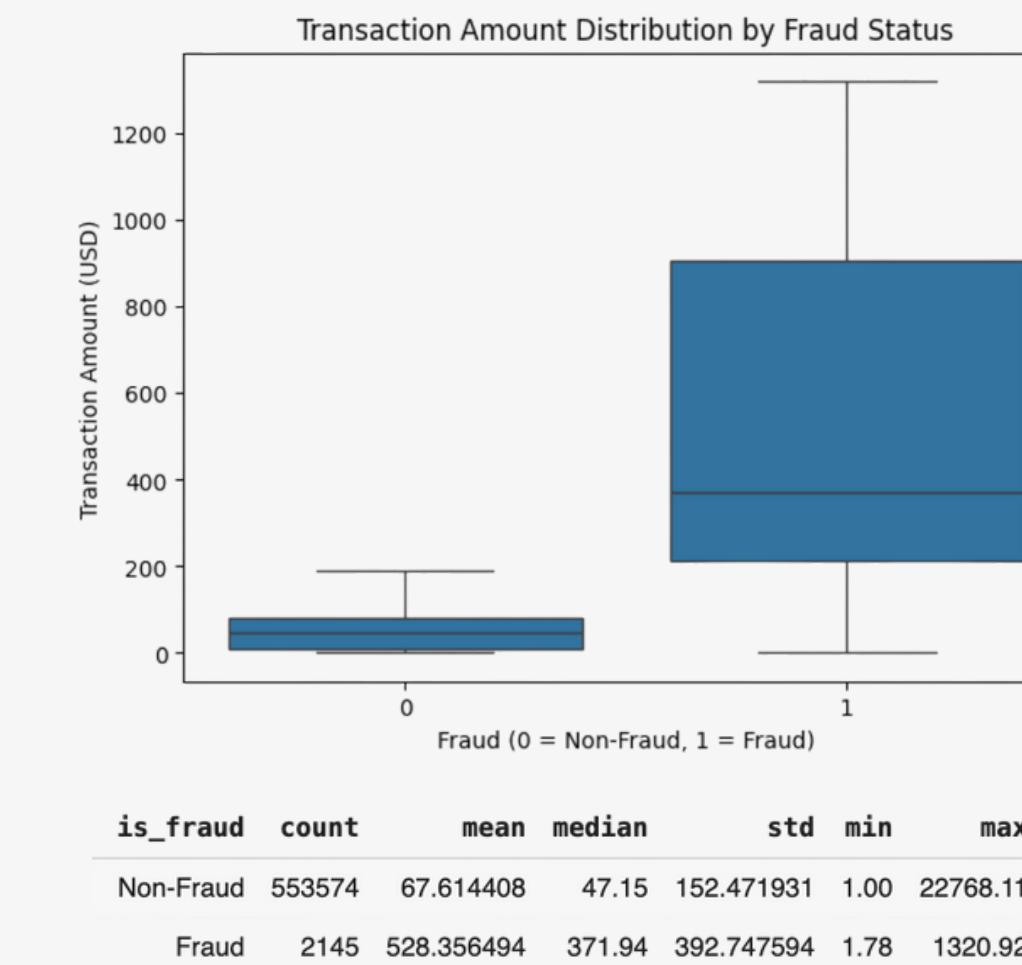


Nominal Transaksi

Nominal transaksi beragam dengan nilai minimum USD 1 dan maksimum USD 22768

Distribusi Nominal Transaksi

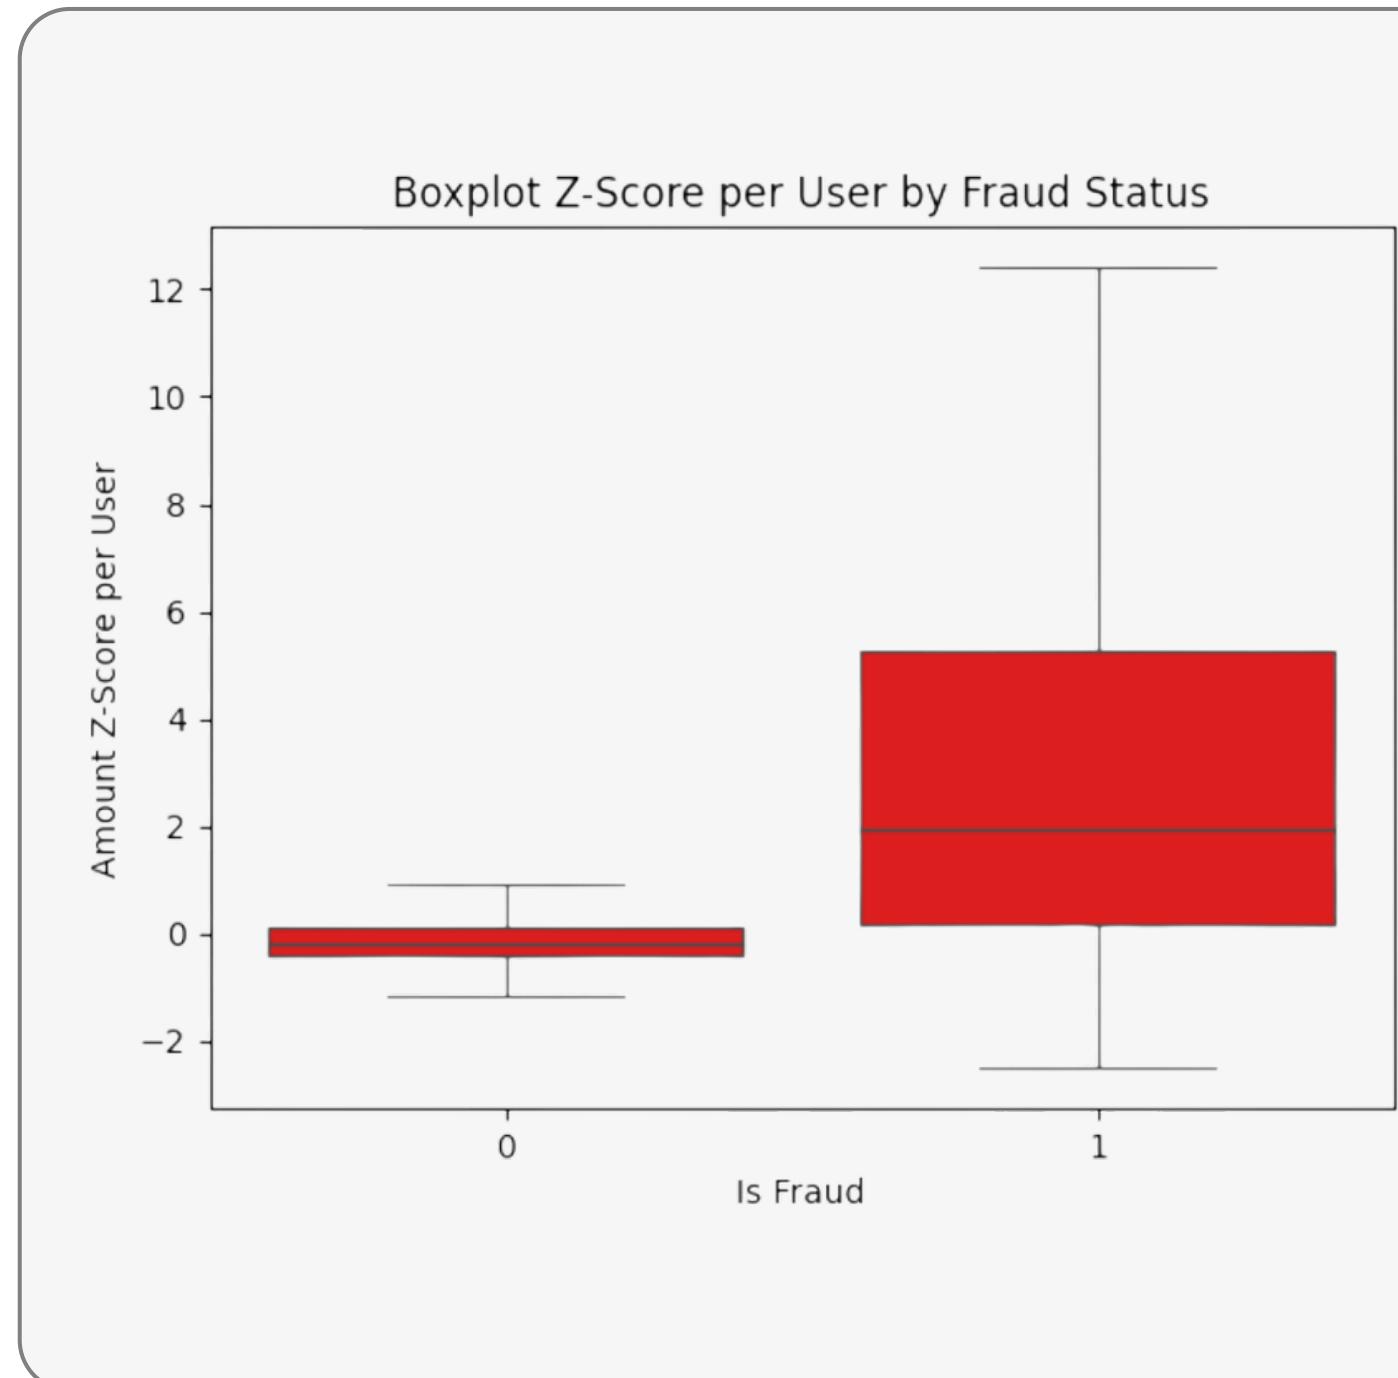
Data didominasi oleh transaksi dengan nominal kecil dengan distribusi data yang sangat miring ke kanan (right-skewed)



Indikasi Fraud pada Transaksi Nominal Besar 🤡

Transaksi fraud cenderung memiliki nominal transaksi yang sangat besar dibandingkan dengan transaksi legitimate. Rata-rata transaksi fraud adalah USD 528 sedangkan non-fraud ada di USD 67

Z SCORE



Z Score Nominal Transaksi

Kolom baru dibuat untuk menghitung Z Score dari nominal transaksi. Kolom ini digunakan sebagai indikator seberapa “uncommon” dengan rata-rata nominal transaksi yang biasa dilakukan oleh pemilik kartu.

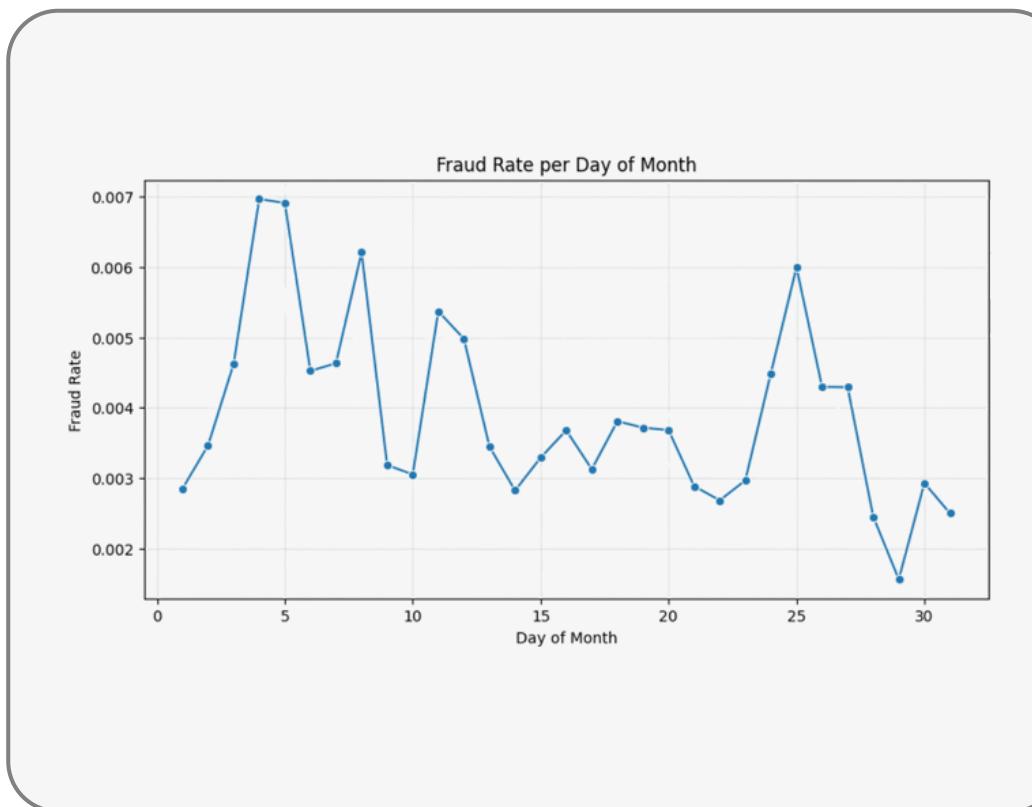
Z Score Tinggi Untuk Transaksi Fraud

Setelah melakukan penghitungan z score untuk tiap transaksi, dapat disimpulkan bahwa transaksi normal umumnya memiliki z score yang mendekati 0.

Di lain sisi, transaksi fraud memiliki z score yang beragam dan dengan nilai besar. Nominal transaksi fraud cenderung berbeda dengan nominal pada umunya yang dilakukan oleh pemegang kartu kredit.

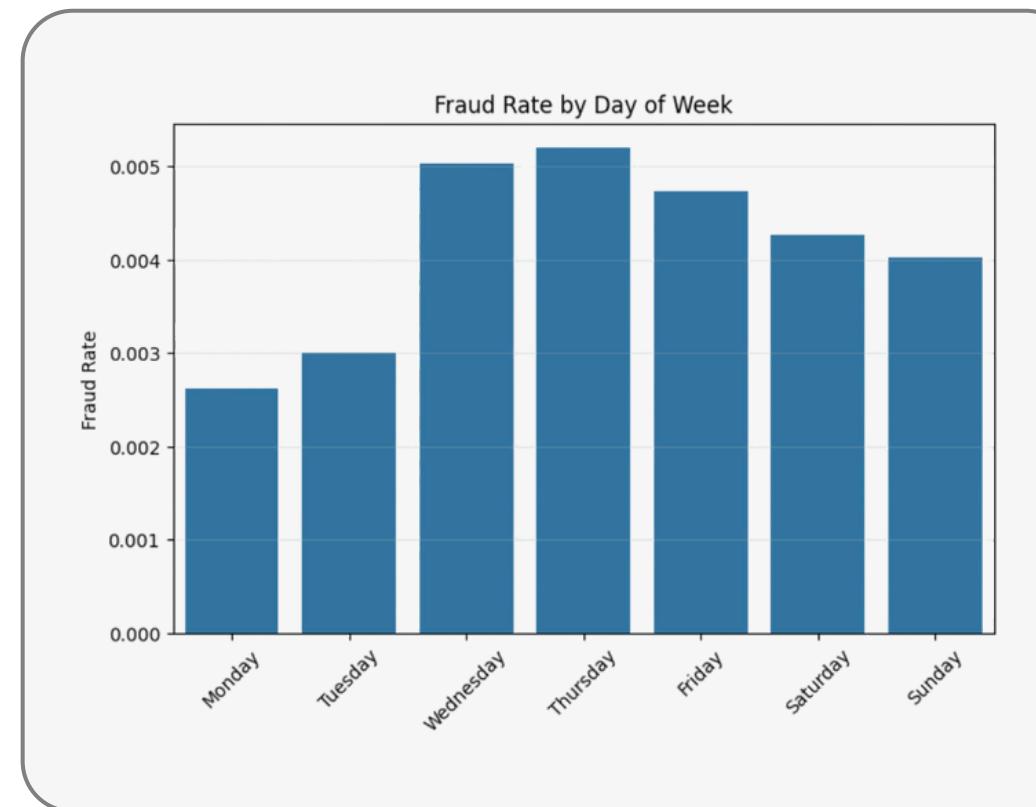
WAKTU TRANSAKSI

3 kolom baru yakni: Tanggal dalam bulan, hari dalam minggu dan jam dalam 1 hari dibuat dari kolom *transaction date* dan *time* untuk eksplorasi yang lebih bermakna



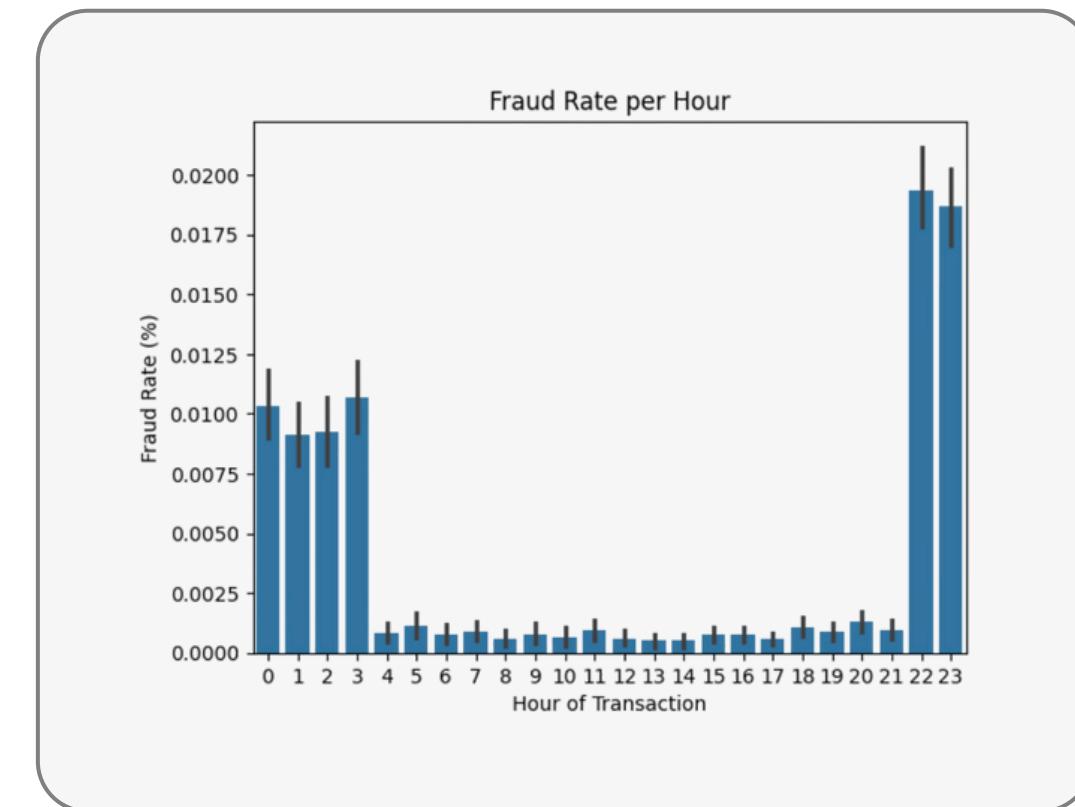
Fluktuasi Pada Tanggal

Berdasarkan tanggal pada bulan, persentase rate tergolong fluktuatif. Tidak ada pola yang dapat ditarik dari sudut pandang ini.



Transaksi Berdasarkan Hari

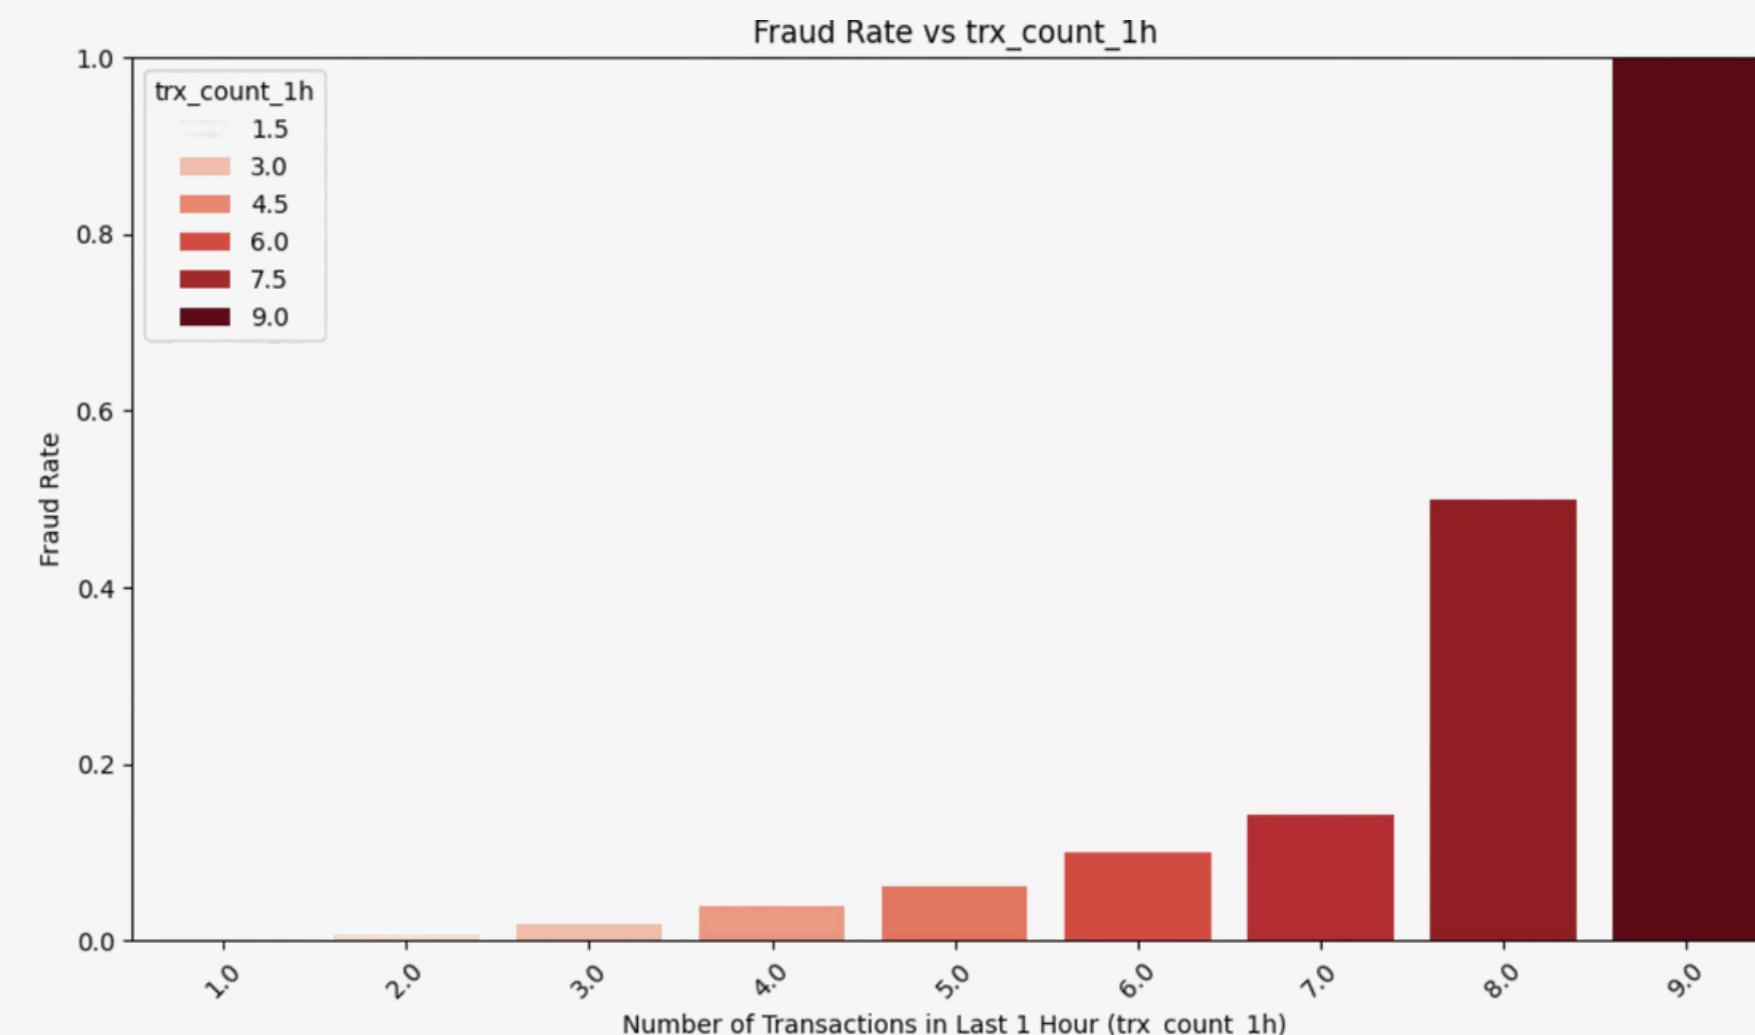
Persentase fraud pada masin-masing hari berada di rentang nilai yang sama.



Transaksi di Malam Hari

Jam malam, khusunya dari jam 22 malam hingga 3 pagi rentang terhadap transaksi fraud.

BANYAK TRANSAKSI DALAM 1 JAM



Rata - Rata Banyak Transaksi Dalam 1 Jam Untuk Transaksi Non-Fraud

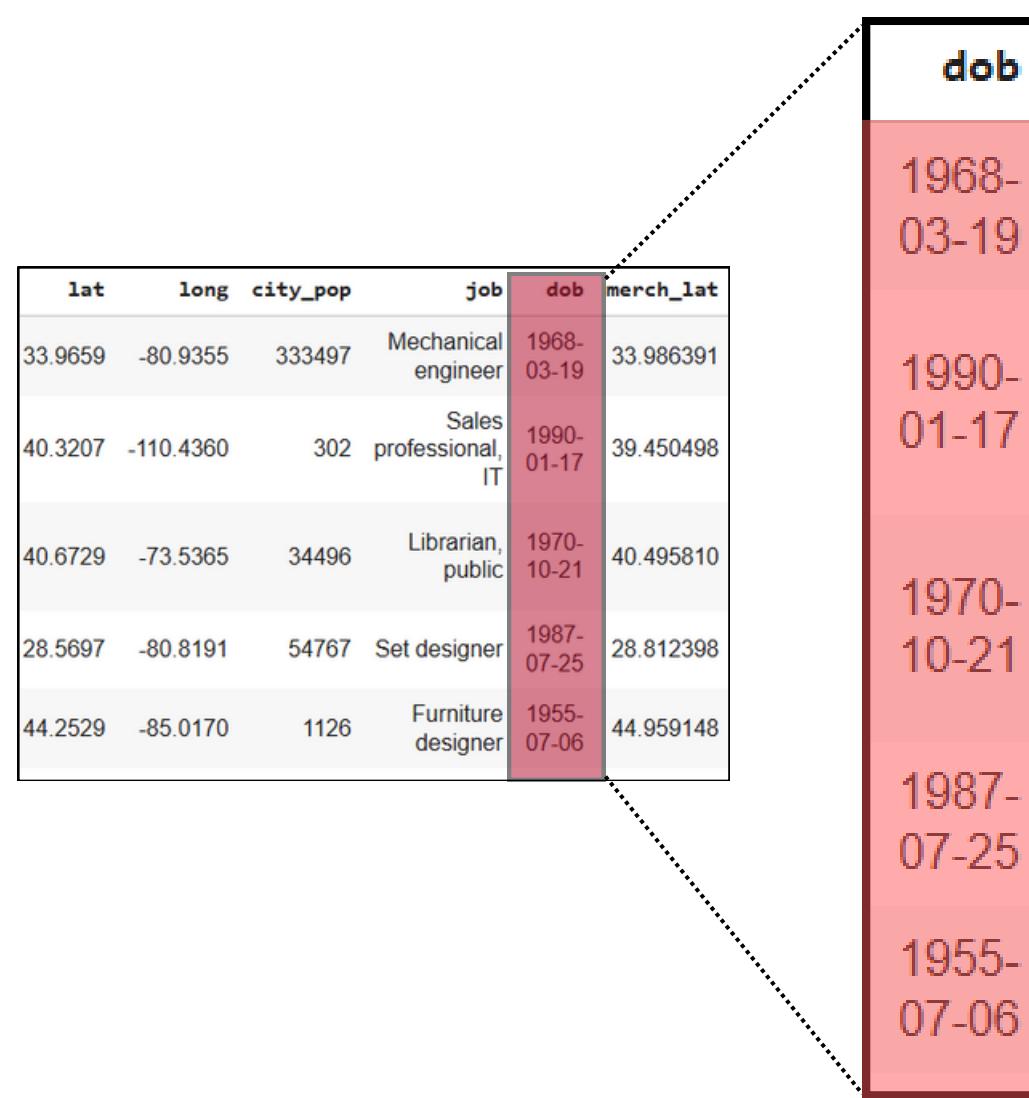
Rata - rata banyak transaksi yang tidak tergolong fraud adalah 1.

Fraud Rate Tinggi Pada Dengan Jumlah Transaksi Lebih dari 2.

Semakin banyak transaksi, fraud rate semakin meningkat. Ini mengindikasikan, percobaan transaksi dilakukan beberapa kali untuk kategori fraud.

DEMOGRAFI PEMILIK KARTU

Univariate Analysis (Analisis Setiap Kolom): kolom ‘trans_date_trans_time’



analisis kolom ‘dob’

data mentah

- data tahun-bulan-lahir dari personal yang melakukan transaksi

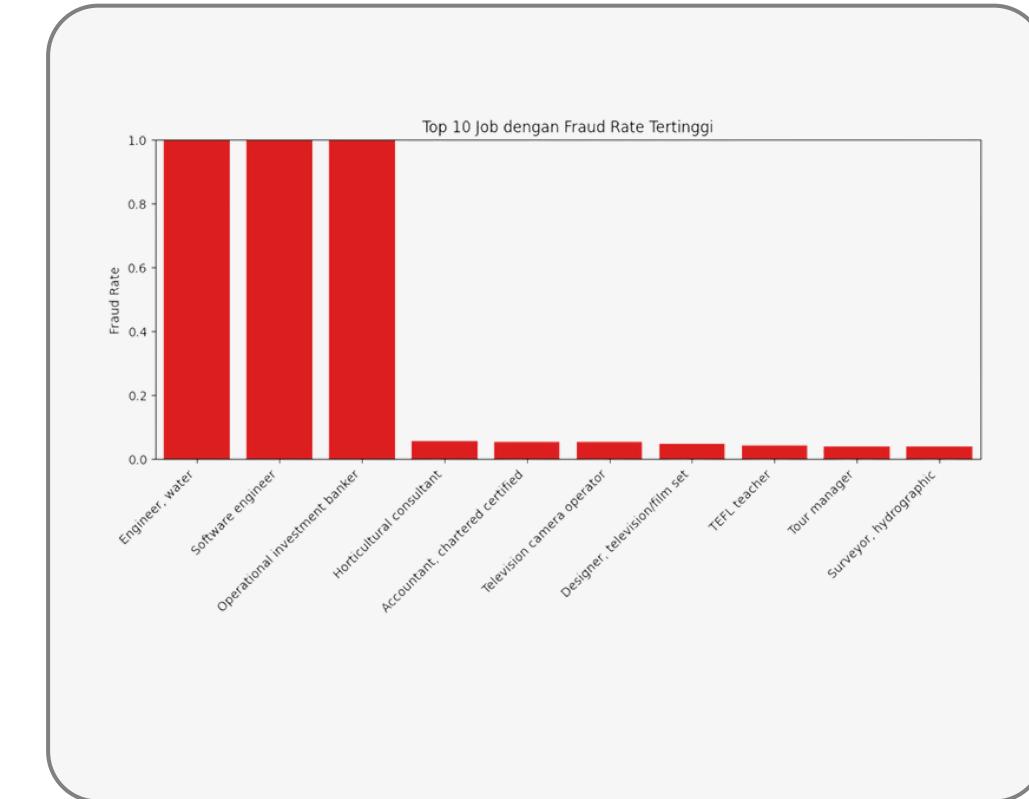
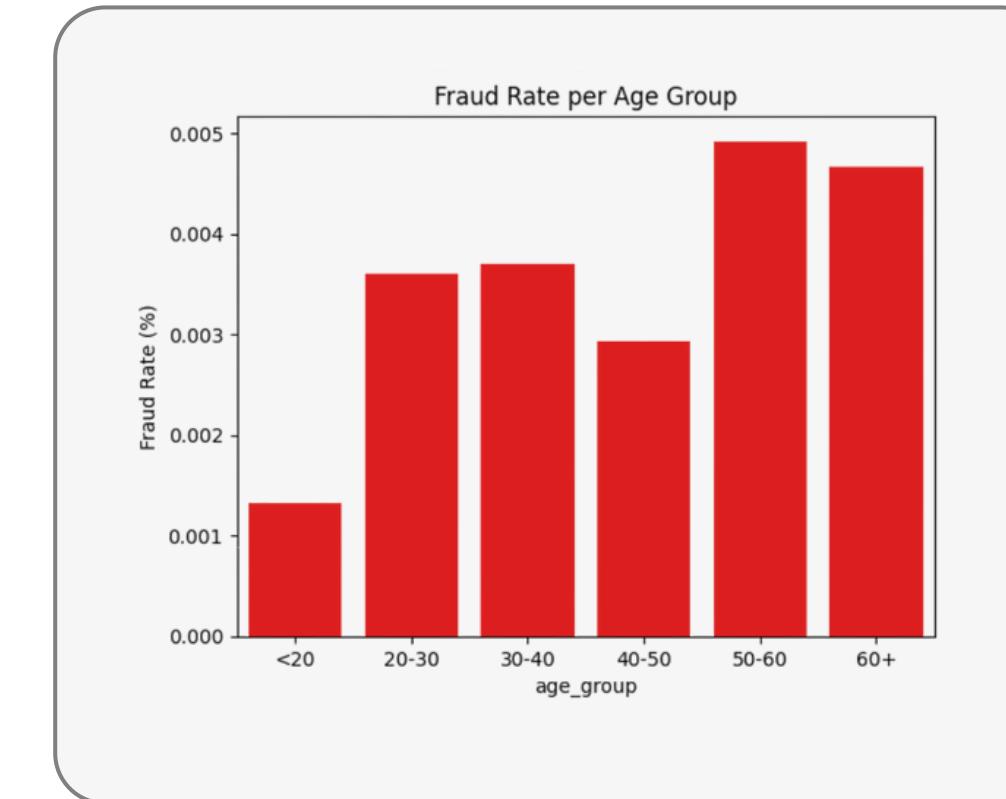
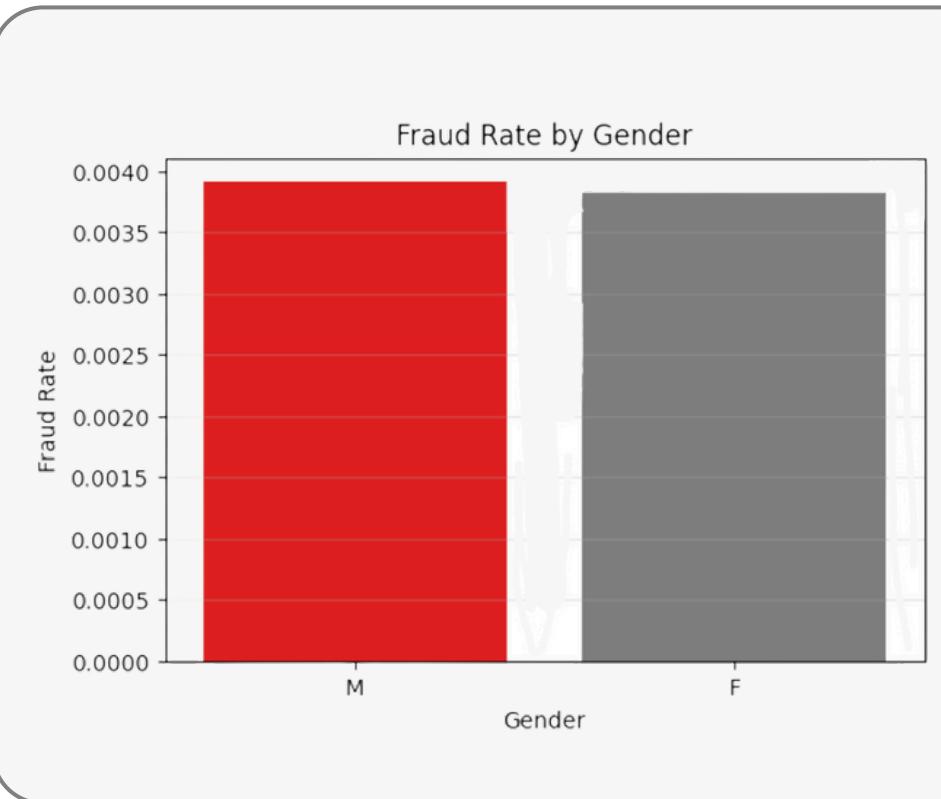
dimensi 1: umur

- didapatkan dari mengurangi tanggal sekarang dengan tanggal lahir

dimensi 2: kelompok umur

- ditentukan dalam mengklasifikasikan kelompok umur menjadi
 - <25
 - 25-40
 - 40-60
 - >60

DEMOGRAFI PEMILIK KARTU



Gender

Tidak ada perbedaan yang signifikan pada *fraud rate* berdasarkan gender. Transaksi *fraud* dapat terjadi ke siapapun terlepas dari gender korban.

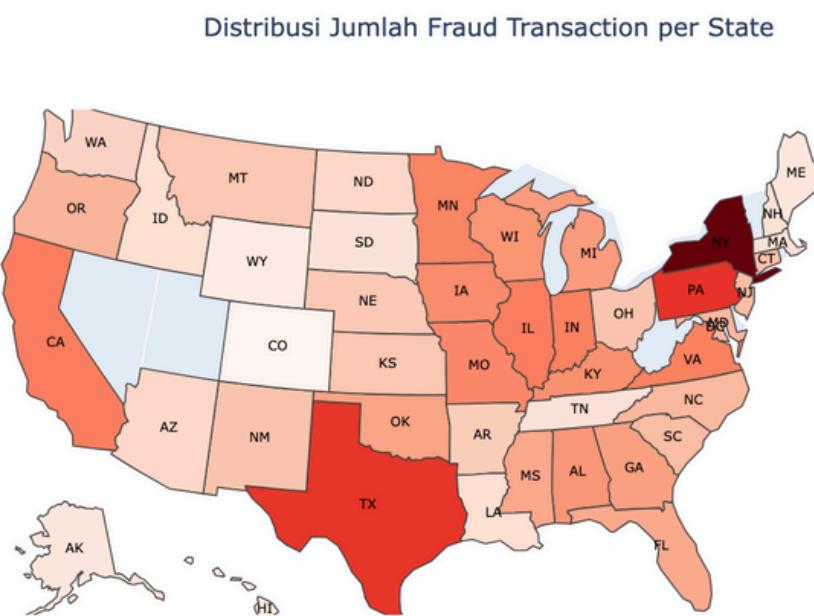
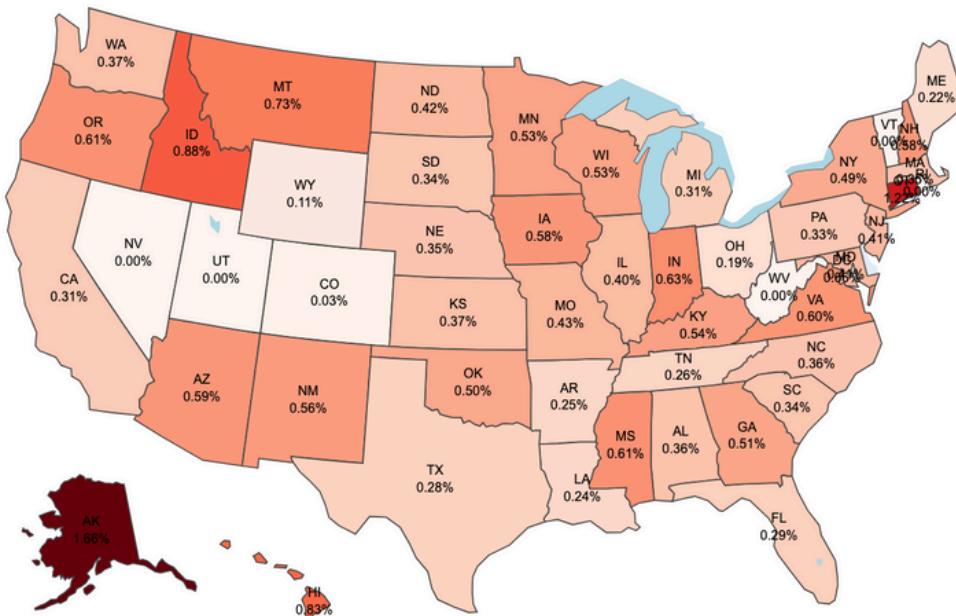
Umur

Di lain sisi, umur cukup memberikan insight bahwa umur lansia cenderung menjadi sasaran *fraud*.

Job

Dari 478 job, hanya 3 (0.006%) yang memiliki *fraud rate* 1%.

ANALISIS GEOGRAFIS

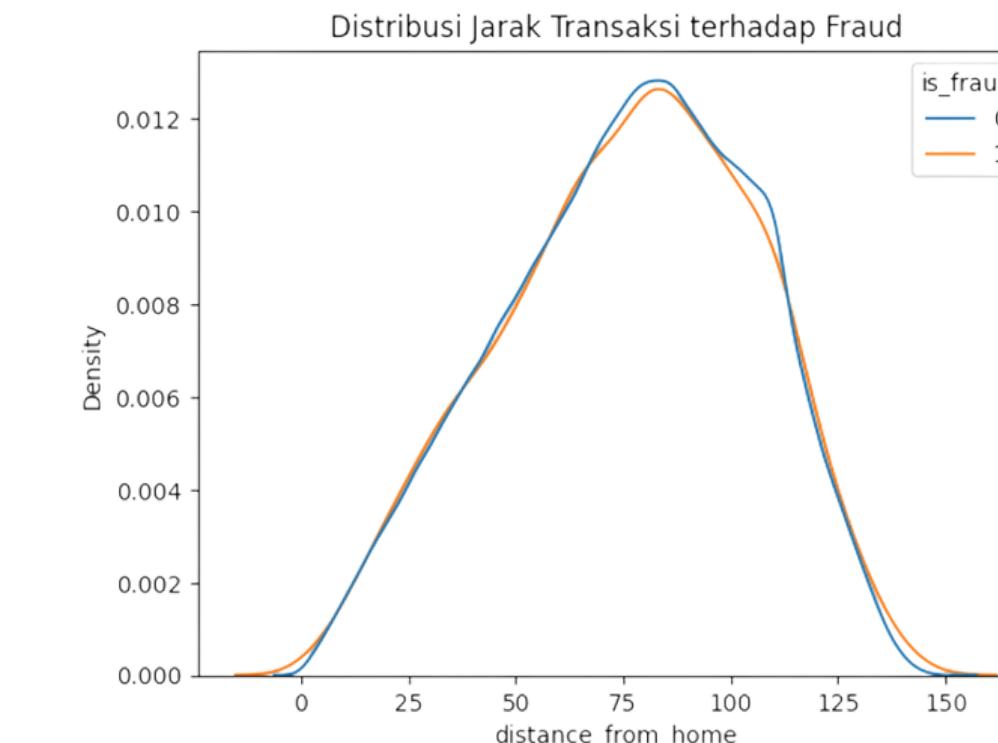


Fraud Rate by State

Rata - rata fraud state dari semua state adalah 0.2% - 0.3%. Alasaka (AK) memiliki fraud rate yang cukup berbeda dengan state yang lain (1.66%)

Fraud Count by State

Berbeda dengan fraud rate, analisis menggunakan fraud count menunjukkan NY dan TX sebagai state dengan kejadian fraud paling banyak.



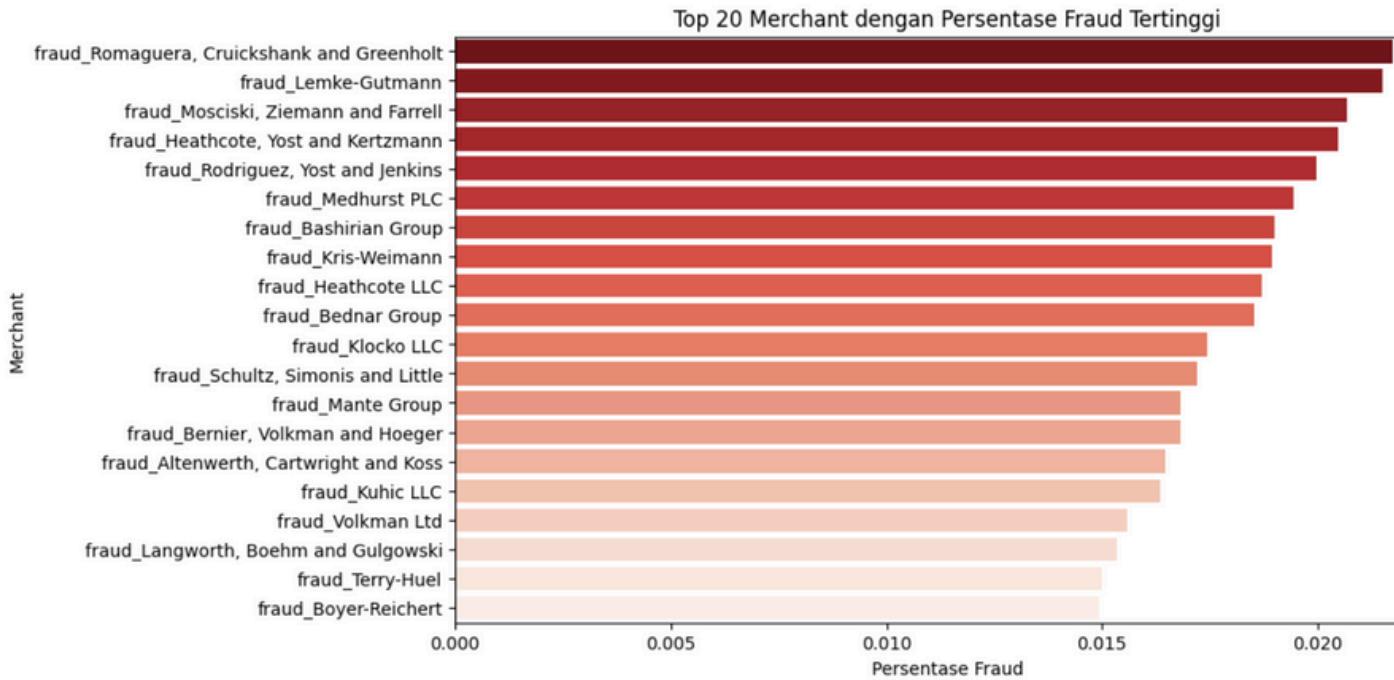
Kesimpulan

Variable geografis tidak memiliki pengaruh yang signifikan pada fraud transaction

Jarak Transaksi

Tidak ada perbedaan yang signifikan dari jarak antara lokasi merchant dengan alamat pemilik kartu untuk transaksi yang normal dan fraud.

MERCHANT TRANSAKSI



Top 20 Merchant by Fraud Rate

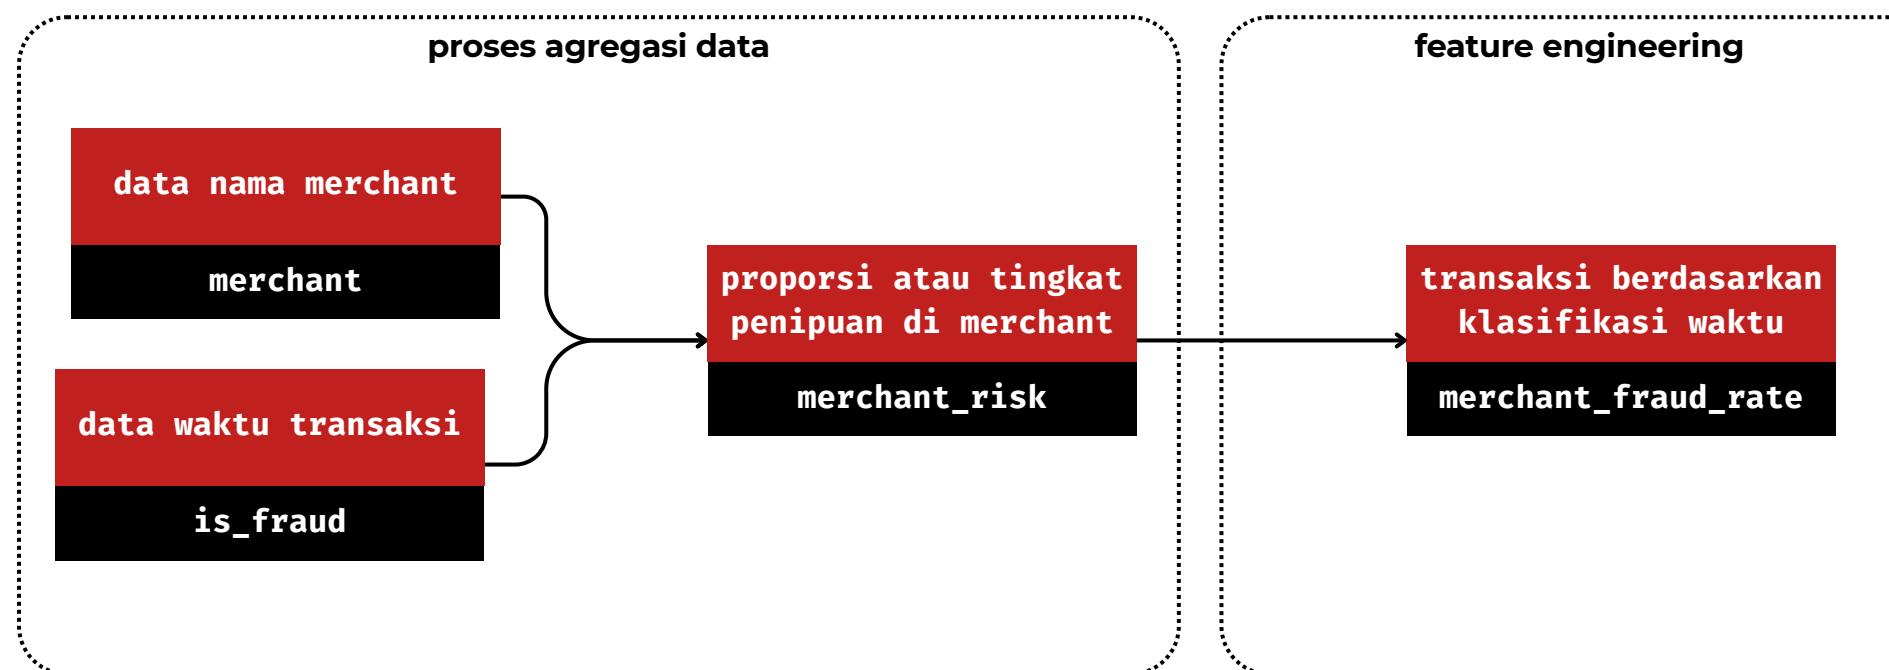
Dari total 693 merchant, terdapat merchant yang memiliki fraud rate yang significant dibanding yang lain. Ini menandakan kemungkinan pengaruh merchant terhadap fraud.



Merchant Fraud Rate

Transaksi yang diidentifikasi sebagai fraud terjadi pada merchant yang secara historis memiliki Fraud Rate yang jauh lebih tinggi.

*Merchant fraud rate diperoleh dari persentase transaksi fraud yang terdapat pada merchant.



PRE PROCESSING & FEATURE SELECTION

Data Preprocessing

Missing Values and Outliers, lalu Handling (if needed)

Missing Value

	Data Type	Missing Value	Unique Value
Unnamed: 0	int64	0	555719
trans_date_trans_time	object	0	544760
cc_num	int64	0	924
merchant	object	0	693
category	object	0	14
amt	float64	0	37256
first	object	0	341
last	object	0	471
gender	object	0	2
street	object	0	924
city	object	0	849
state	object	0	50
zip	int64	0	912
lat	float64	0	910
long	float64	0	910
city_pop	int64	0	835
job	object	0	478
dob	object	0	910
trans_num	object	0	555719
unix_time	int64	0	544760
merch_lat	float64	0	546490
merch_long	float64	0	551770
is_fraud	int64	0	2

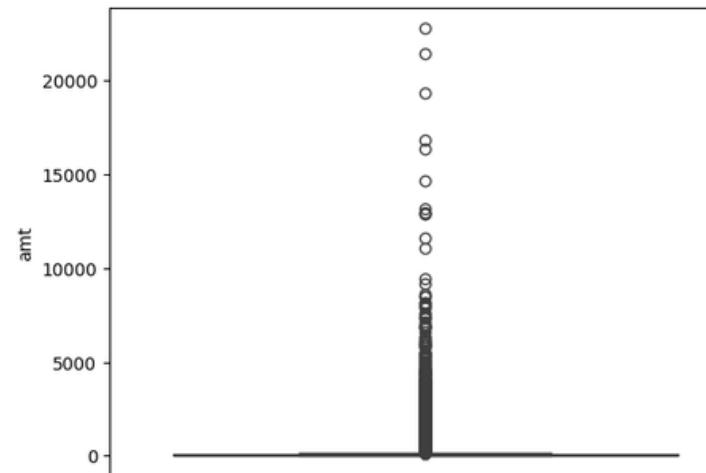
Outliers

```
Q1 = transaction['amt'].quantile(0.25)
Q3 = transaction['amt'].quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

print(f'Lower Bound: {lower_bound}')
print(f'Upper Bound: {upper_bound}')

Lower Bound: -100.44000000000003
Upper Bound: 193.08000000000004
```



Missing value

- Tidak ada kolom yang memiliki missing values

Outliers

- Outliers akan dipertahankan karena memang tujuan analisa berikut adalah untuk mendeteksi terjadinya fraud.

PRE PROCESSING & FINAL FEATURE SELECTION

TRANSFORM

Jam Transaksi - `is_night`

Jam transaksi ditransformasi menjadi data biner dengan logic jam 22 malam hingga 5 pagi adalah jam malam.

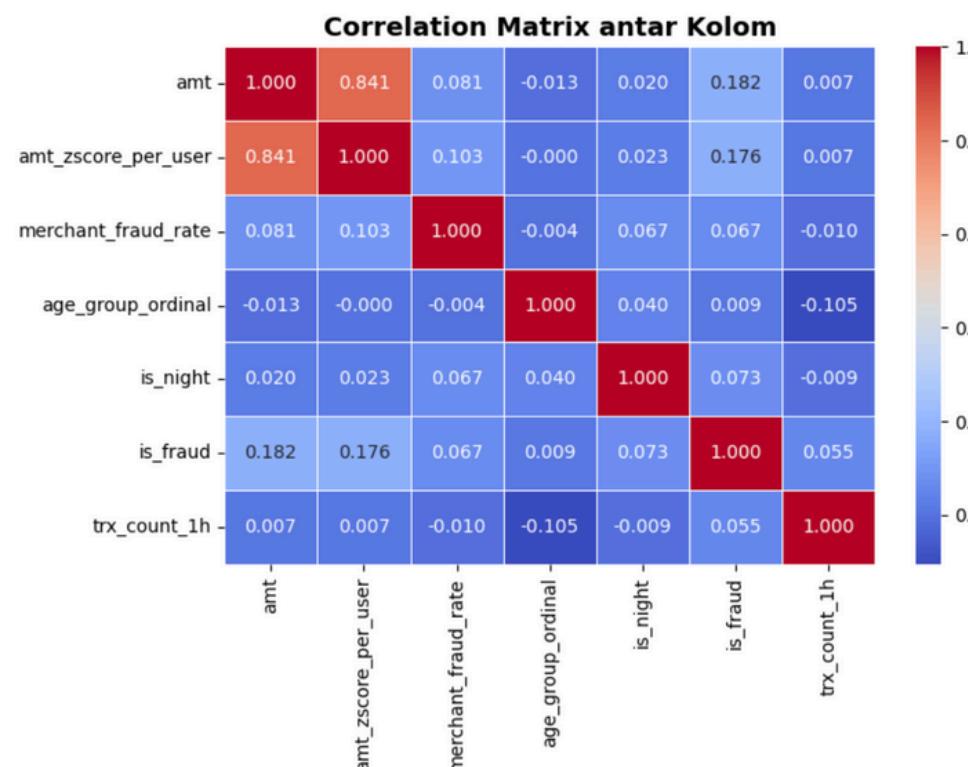
Kelompok Umur - `age_group_ordinal`

Kelompok umur diubah menjadi data numerik dengan ordinal encoding dengan asumsi semakin tua, resiko semakin meningkat (urutan alami)

Kolom Lainnya

Nominal transaksi (`amt`), `merchant_fraud_rate`, dan `trx_count_1h` dan 'amt_zscore_per_user', tidak ditransform.

ANALISIS KORELASI



MULTIKOLIENARITAS

`amt_zscore_per_user` dan `amt` memiliki korelasi yang tinggi ($VIF > 5$).

`amt` dipilih karena memiliki korelasi yang sedikit lebih besar dibandingkan dengan `amt_zscore_per_user`

PEMILIHAN KOLOM

Kolom yang termasuk dalam model: `amt`, `is_night`, `trx_count_1h` dan `merchant_fraud_rate`

MODELING & EVALUATION

MODELING - PHASE I

Logistic Regression	Decision Tree	Random Forest	AdaBoost																																																																																																																								
<pre>class_weight='balanced', solver='lbfgs', max_iter=1000,</pre>	<pre>class_weight='balanced'</pre>	<pre>n_estimators=200, class_weight='balanced', n_jobs=-1</pre>	<pre>n_estimators=200, learning_rate=0.1, random_state=42</pre>																																																																																																																								
<table> <thead> <tr> <th></th><th>precision</th><th>recall</th><th>f1-score</th><th>support</th></tr> </thead> <tbody> <tr> <td>0</td><td>0.9990</td><td>0.8938</td><td>0.9434</td><td>110715</td></tr> <tr> <td>1</td><td>0.0269</td><td>0.7576</td><td>0.0519</td><td>429</td></tr> <tr> <td>accuracy</td><td></td><td></td><td>0.8932</td><td>111144</td></tr> <tr> <td>macro avg</td><td>0.5129</td><td>0.8257</td><td>0.4977</td><td>111144</td></tr> <tr> <td>weighted avg</td><td>0.9952</td><td>0.8932</td><td>0.9400</td><td>111144</td></tr> </tbody> </table> <p>ROC AUC: 0.9037</p>		precision	recall	f1-score	support	0	0.9990	0.8938	0.9434	110715	1	0.0269	0.7576	0.0519	429	accuracy			0.8932	111144	macro avg	0.5129	0.8257	0.4977	111144	weighted avg	0.9952	0.8932	0.9400	111144	<table> <thead> <tr> <th></th><th>precision</th><th>recall</th><th>f1-score</th><th>support</th></tr> </thead> <tbody> <tr> <td>0</td><td>0.9979</td><td>0.9983</td><td>0.9981</td><td>110715</td></tr> <tr> <td>1</td><td>0.5104</td><td>0.4592</td><td>0.4834</td><td>429</td></tr> <tr> <td>accuracy</td><td></td><td></td><td>0.9962</td><td>111144</td></tr> <tr> <td>macro avg</td><td>0.7541</td><td>0.7288</td><td>0.7408</td><td>111144</td></tr> <tr> <td>weighted avg</td><td>0.9960</td><td>0.9962</td><td>0.9961</td><td>111144</td></tr> </tbody> </table> <p>ROC AUC: 0.7288</p>		precision	recall	f1-score	support	0	0.9979	0.9983	0.9981	110715	1	0.5104	0.4592	0.4834	429	accuracy			0.9962	111144	macro avg	0.7541	0.7288	0.7408	111144	weighted avg	0.9960	0.9962	0.9961	111144	<table> <thead> <tr> <th></th><th>precision</th><th>recall</th><th>f1-score</th><th>support</th></tr> </thead> <tbody> <tr> <td>0</td><td>0.9978</td><td>0.9994</td><td>0.9986</td><td>110715</td></tr> <tr> <td>1</td><td>0.7341</td><td>0.4312</td><td>0.5433</td><td>429</td></tr> <tr> <td>accuracy</td><td></td><td></td><td>0.9972</td><td>111144</td></tr> <tr> <td>macro avg</td><td>0.8660</td><td>0.7153</td><td>0.7710</td><td>111144</td></tr> <tr> <td>weighted avg</td><td>0.9968</td><td>0.9972</td><td>0.9968</td><td>111144</td></tr> </tbody> </table> <p>ROC AUC: 0.9308</p>		precision	recall	f1-score	support	0	0.9978	0.9994	0.9986	110715	1	0.7341	0.4312	0.5433	429	accuracy			0.9972	111144	macro avg	0.8660	0.7153	0.7710	111144	weighted avg	0.9968	0.9972	0.9968	111144	<table> <thead> <tr> <th></th><th>precision</th><th>recall</th><th>f1-score</th><th>support</th></tr> </thead> <tbody> <tr> <td>0</td><td>0.9961</td><td>1.0000</td><td>0.9981</td><td>110715</td></tr> <tr> <td>1</td><td>0.0000</td><td>0.0000</td><td>0.0000</td><td>429</td></tr> <tr> <td>accuracy</td><td></td><td></td><td>0.9961</td><td>111144</td></tr> <tr> <td>macro avg</td><td>0.4981</td><td>0.5000</td><td>0.4990</td><td>111144</td></tr> <tr> <td>weighted avg</td><td>0.9923</td><td>0.9961</td><td>0.9942</td><td>111144</td></tr> </tbody> </table> <p>ROC AUC: 0.9565</p>		precision	recall	f1-score	support	0	0.9961	1.0000	0.9981	110715	1	0.0000	0.0000	0.0000	429	accuracy			0.9961	111144	macro avg	0.4981	0.5000	0.4990	111144	weighted avg	0.9923	0.9961	0.9942	111144
	precision	recall	f1-score	support																																																																																																																							
0	0.9990	0.8938	0.9434	110715																																																																																																																							
1	0.0269	0.7576	0.0519	429																																																																																																																							
accuracy			0.8932	111144																																																																																																																							
macro avg	0.5129	0.8257	0.4977	111144																																																																																																																							
weighted avg	0.9952	0.8932	0.9400	111144																																																																																																																							
	precision	recall	f1-score	support																																																																																																																							
0	0.9979	0.9983	0.9981	110715																																																																																																																							
1	0.5104	0.4592	0.4834	429																																																																																																																							
accuracy			0.9962	111144																																																																																																																							
macro avg	0.7541	0.7288	0.7408	111144																																																																																																																							
weighted avg	0.9960	0.9962	0.9961	111144																																																																																																																							
	precision	recall	f1-score	support																																																																																																																							
0	0.9978	0.9994	0.9986	110715																																																																																																																							
1	0.7341	0.4312	0.5433	429																																																																																																																							
accuracy			0.9972	111144																																																																																																																							
macro avg	0.8660	0.7153	0.7710	111144																																																																																																																							
weighted avg	0.9968	0.9972	0.9968	111144																																																																																																																							
	precision	recall	f1-score	support																																																																																																																							
0	0.9961	1.0000	0.9981	110715																																																																																																																							
1	0.0000	0.0000	0.0000	429																																																																																																																							
accuracy			0.9961	111144																																																																																																																							
macro avg	0.4981	0.5000	0.4990	111144																																																																																																																							
weighted avg	0.9923	0.9961	0.9942	111144																																																																																																																							

Highlights:

- **AUC 0.90.** Kinerja model baik.
- Model **berhasil mengenali 75% transaksi fraud.**
- Precision 0.02. Meskipun demikian, **model ini juga sering salah mengenali transaksi fraud** (banyak juga yang nyatanya adalah transaksi non-fraud).

Highlights:

- AUC 0.72. Kinerja tidak lebih baik dari Logistic Regression.
- Precision dan Recall memiliki nilai yg cukup seimbang.

Highlights:

- AUC 0.93.
- Memiliki precision yang tinggi (0.73), Model lumayan baik dalam menebak transaksi fraud.
- Meskipun demikian, recall (0.4) masih tergolong rendah. Model belum banyak menangkap transaksi fraud

Highlights:

- AUC 0.95. Memiliki potensi yang baik.
- Nilai precision dan recall 0. Model sama sekali tidak mendapatkan kasus fraud.

Test : Train = 80 : 20

MODELING - PHASE II - TUNING

Logistic Regression	Decision Tree	Random Forest	AdaBoost
C=0.001, penalty='l2', solver='saga', class_weight='balanced', max_iter=1000,	criterion='entropy', max_depth=5, min_samples_split=2, min_samples_leaf=1, class_weight='balanced',	n_estimators=200, max_depth=20, class_weight='balanced', n_jobs=-1	n_estimators=200, learning_rate=0.1, random_state=42

	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support		[[110715 429 0 0]]	precision	recall	f1-score	support		
0	0.9990	0.8950	0.9441	110715		0	0.9997	0.9134	0.9546	110715		0	0.9982	0.9985	0.9983	110715		0	0.9961	1.0000	0.9981	110715
1	0.0272	0.7576	0.0525	429		1	0.0395	0.9184	0.0757	429		1	0.5758	0.5315	0.5527	429		1	0.0000	0.0000	0.0000	429
accuracy			0.8944	111144		accuracy			0.9134	111144		accuracy			0.9967	111144		accuracy			0.9961	111144
macro avg	0.5131	0.8263	0.4983	111144		macro avg	0.5196	0.9159	0.5151	111144		macro avg	0.7870	0.7650	0.7755	111144		macro avg	0.4981	0.5000	0.4990	111144
weighted avg	0.9952	0.8944	0.9407	111144		weighted avg	0.9959	0.9134	0.9512	111144		weighted avg	0.9966	0.9967	0.9966	111144		weighted avg	0.9923	0.9961	0.9942	111144
ROC AUC (Test):	0.9038					ROC AUC (Test):	0.9660					ROC AUC:	0.9703					ROC AUC:	0.9577			

Highlights:

- Nilai AUC sama dengan model Phase I.
- Nilai recall sama.
- Precision sedikit naik 0.0272 (2.72%)

Highlights:

- AUC 0.96. Kinerja jauh lebih baik dari Phase I.
- Model dapat mengenali 91% dari transaksi fraud.
- Meskipun demikian, presisi masih kecil. Model masih sering memberikan false alarm (sama seperti LR)

Highlights:

- AUC 0.97.
- Nilai precision dan recall cukup seimbang.
- Meskipun model hanya dapat menangkap 53% dari total kasus fraud, model dapat mengenali actual fraud transaction hingga 57%

Highlights:

- AUC 0.95.
- Nilai precision dan recall 0. Model sama sekali tidak mendapatkan kasus fraud.

Test : Train = 80 : 20

MODELING - PHASE III - SMOTE

Logistic Regression					Decision Tree					Random Forest					AdaBoost				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support
0	0.9989	0.9001	0.9469	110715	0	0.9995	0.9416	0.9697	110715	0	0.9989	0.9880	0.9934	110715	0	0.9995	0.9422	0.9700	110715
1	0.0283	0.7506	0.0545	429	1	0.0544	0.8671	0.1024	429	1	0.1867	0.7110	0.2957	429	1	0.0559	0.8834	0.1051	429
accuracy					accuracy					accuracy					accuracy				
macro avg	0.5136	0.8253	0.5007	111144	macro avg	0.5269	0.9044	0.5360	111144	macro avg	0.5928	0.8495	0.6445	111144	macro avg	0.5277	0.9128	0.5376	111144
weighted avg	0.9952	0.8995	0.9435	111144	weighted avg	0.9958	0.9413	0.9663	111144	weighted avg	0.9957	0.9869	0.9907	111144	weighted avg	0.9959	0.9419	0.9667	111144
ROC AUC: 0.9071					ROC AUC: 0.9579					ROC AUC: 0.9776					ROC AUC: 0.9608				

Highlights:

- Nilai AUC sama dengan model Phase I.
- Nilai recall sama.
- Precision sedikit naik di 0.028

Highlights:

- Nilai recall turun namun presisi naik menjadi 0.5%

Highlights:

- Nilai recall meningkat signifikan hingga 71%
- Meskipun demikian, precision mengalami penurunan ke 18%

Highlights:

- Dengan SMOTE, model kini dapat menangkap 88% data fraud.
- Meskipun demikian, presisi masih sangat kecil.

Test : Train = 80 : 20

FEATURE IMPORTANCE

Logistic Regression	Decision Tree	Random Forest	AdaBoost
<ul style="list-style-type: none">• is_night (1.09)• amt (1.07)• trx_count_1h (0.29)• merchant_fraud_rate (0.18)• age_group_ordinal (0.07)	<ul style="list-style-type: none">• amt (0.75)• merchant_fraud_rate (0.12)• is_night (0.07)• trx_count_1h (0.01)	<ul style="list-style-type: none">• amt (0.59)• merchant_fraud_rate (0.18)• is_night (0.17)• trx_count_1h (0.3)• age_group_ordinal (0.01)	<ul style="list-style-type: none">• amt (0.61)• is_night (0.20)• merchant_fraud_rate (0.18)

Highlights:

- AMT menjadi data yang paling berpengaruh pada semua model. Data ini menjadi komponen penting dalam mengenali transaksi fraud.
- Data lain yang juga cukup penting: merchant_fraud_rate dan is_night

Test : Train = 80 : 20

KESIMPULAN

- Semua model sudah berhasil mencapai ROC $\geq 90\%$, model sudah cukup baik dalam memisahkan antara fraud dan non fraud.
- Meskipun demikian, semua model masih memiliki presisi yang rendah. yang berarti masih banyak false positive.
- Random Forest memberikan trade-off terbaik antara recall dan precision, sehingga paling layak dipertimbangkan untuk pengembangan tahap awal.

FUTURE IMPROVEMENT

- Mengimplementasikan **GridSearchCV** sebagai hyperparameter tuning
- Mencoba balancing dengan ADASYN (Adaptive Synthetic Sampling)
- Mencoba **Bayesian Optimization** (Optuna, Hyperopt)
- Mengimplementasikan **nested cross-validation**
- Mencoba **model training lain** misalnya Light GBM dan sebagainya
- Karena model training difokuskan pada recall untuk deteksi fraud dalam skala tinggi maka precision dikorbankan, untuk improvement mungkin bisa diterapkan **balance antara recall dan juga operational efficiency** dimana kalau precision drop maka banyak kemungkinan terdapat data false alarm yang membuat cost untuk cek kebenarannya meningkat, jadi lebih baik dioptimalkan untuk segi cost operasional bisnis juga

